BÁO CÁO BÀI TẬP LỚN CO4031

Kho dữ liệu thương mại điện tử Olist và hệ hỗ trợ ra quyết định

Phần B: Dashboard phân tích và Hệ hỗ trợ ra quyết định (DSS)

Vỹ (Người B – Ứng dụng & DSS)

Học kỳ 261 – Năm học 2026–2027

Mục lục

1 Kiến trúc dashboard và DSS **2**
- 1.1 Vị trí trong hệ thống . . . 2
- 1.2 Các tầng . . . 2

2 Dashboard Streamlit **3**
- 2.1 Trang 1 – Tổng quan (`page_overview`) . . . 3
- 2.2 Trang 2 – Phân tích đa chiều (OLAP) (`page_olap`) . . . 3
- 2.3 Trang 3 – Địa lý & khách hàng (`page_geo_customer`) . . . 3
- 2.4 Trang 4 – Giao hàng & hài lòng (`page_delivery`) . . . 3
- 2.5 Trang 5 – Dự báo & DSS (`page_dss`) . . . 4

3 Mô hình DSS **4**
- 3.1 Dự báo doanh thu (`src/dss/forecast.py`) . . . 4
- 3.2 Phân khúc khách hàng RFM + K-Means (`src/dss/rfm.py`) . . . 7
- 3.3 Mô hình what-if (`src/dss/whatif.py`) . . . 8

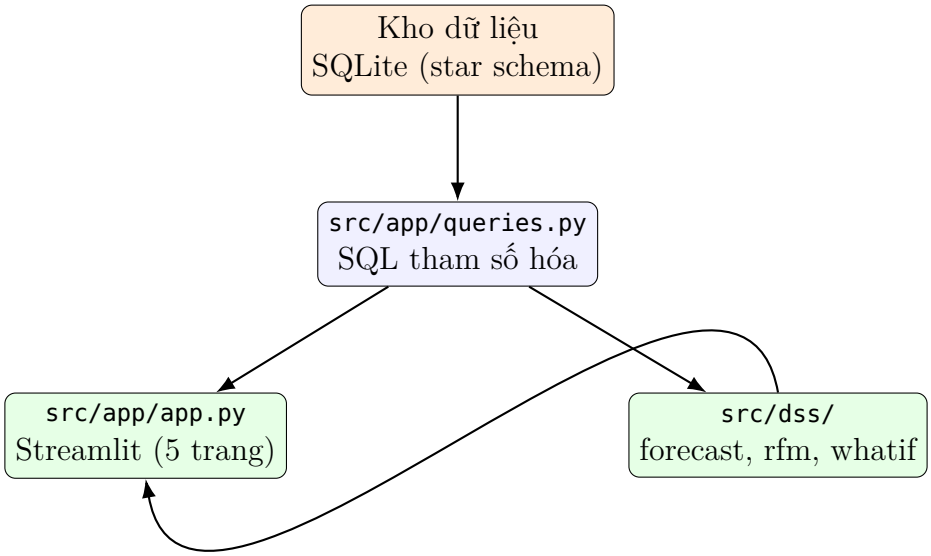
4 Đánh giá **9**

5 Hạn chế và hướng phát triển **10**
- 5.1 Hạn chế hiện tại . . . 10
- 5.2 Hướng phát triển . . . 10

1 Kiến trúc dashboard và DSS

1.1 Vị trí trong hệ thống

Phần B dùng lại kho dữ liệu (DW) do phần A xây dựng, không đọc lại các tệp CSV gốc. Theo hợp đồng dữ liệu giữa hai phần (`docs/data_contract.md`), phần B *chỉ đọc* từ tệp `data/processed/olist_dw.db` đã được ETL của phần A nạp sẵn theo lược đồ star schema (`src/sql/01_schema.sql`). Phần B không được tự sửa lược đồ hay đọc CSV trực tiếp, để tránh hai phần xung đột dữ liệu.



Hình 1: Kiến trúc dashboard và DSS: giao diện và các mô hình DSS đều chỉ truy cập DW qua một tầng truy vấn SQL duy nhất

1.2 Các tầng

- **Tầng truy vấn (`src/app/queries.py`).** Toàn bộ câu SQL đọc DW nằm trong một tệp duy nhất. Mọi điều kiện lọc (năm, bang, danh mục…) dùng tham số `?` của `sqlite3`, không nối chuỗi, tránh SQL injection và giữ quy ước doanh thu `SUM(price)`, loại đơn `canceled`/`unavailable` thống nhất ở một chỗ (hàm `_not_canceled_clause`).
- **Tầng giao diện (`src/app/app.py`).** Ứng dụng Streamlit, chỉ gọi hàm ở `queries.py` và ba mô-đun DSS, không bao giờ mở kết nối CSDL trực tiếp. Mỗi hàm truy vấn được bọc bằng `@st.cache_data` để không truy vấn lại DW mỗi lần người dùng tương tác với widget.
- **Tầng DSS (`src/dss/forecast.py`, `rfm.py`, `whatif.py`).** Ba mô-đun độc lập, có thể

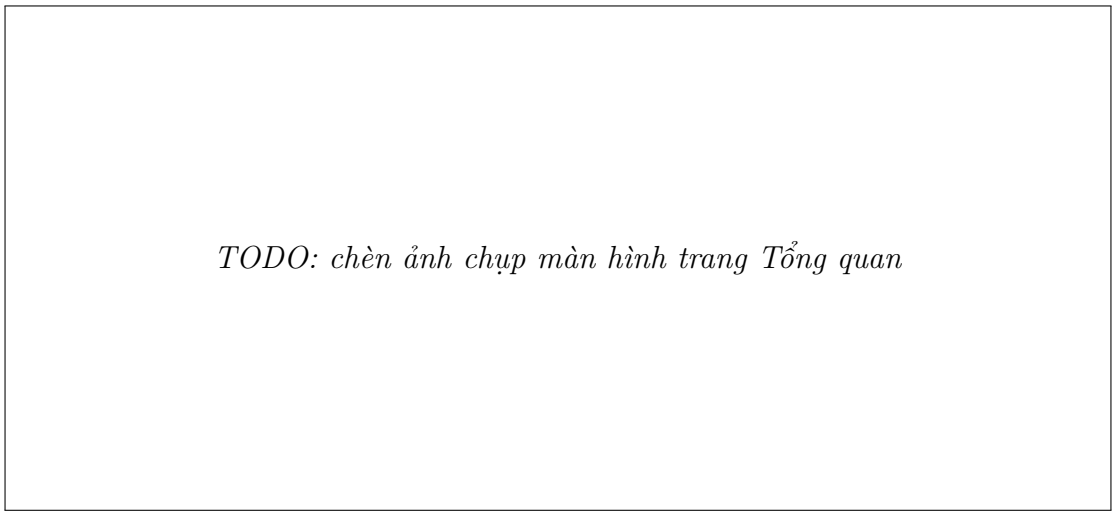
chạy trực tiếp bằng dòng lệnh (`python src/dss/forecast.py`) để kiểm tra kết quả ngoài giao diện, đồng thời được `app.py` import và gọi lại trong trang *Dự báo & DSS*.

2 Dashboard Streamlit

Dashboard gồm 5 trang, chọn qua `st.sidebar.radio` (hàm `main()` trong `app.py`, biến `PAGES`).

2.1 Trang 1 – Tổng quan (`page_overview`)

Hiển thị 5 chỉ số KPI (doanh thu, số đơn, giá trị đơn trung bình, điểm đánh giá trung bình, % giao trễ) từ `kpi_summary()`, và biểu đồ đường doanh thu theo tháng từ `monthly_revenue()`.



Hình 2: Trang Tổng quan của dashboard

2.2 Trang 2 – Phân tích đa chiều (OLAP) (`page_olap`)

Đây là trang chứng minh năm phép toán OLAP theo yêu cầu đề bài, mỗi phép toán ứng với một hàm riêng trong `queries.py` (Bảng 1).

2.3 Trang 3 – Địa lý & khách hàng (`page_geo_customer`)

Biểu đồ cột doanh thu theo bang, tô màu theo điểm đánh giá trung bình (`revenue_review_by_state()`), và biểu đồ tròn cơ cấu doanh thu theo hình thức thanh toán (`payment_mix()`).

2.4 Trang 4 – Giao hàng & hài lòng (`page_delivery`)

So sánh điểm đánh giá trung bình và số ngày giao trung bình giữa nhóm giao trễ và đúng hạn (`delivery_vs_review()`), rồi tách theo 10 bang và 10 danh mục có số lượng dòng hàng lớn nhất (`delivery_vs_review_by_state()`, `delivery_vs_review_by_category()`).

Bảng 1: Ánh xạ phép toán OLAP sang hàm truy vấn và thành phần giao diện

Phép toán	**Hàm (`queries.py`)**	**Thao tác trên giao diện**
Roll-up	`rollup_by_year()`	Tổng hợp doanh thu từ mức tháng lên mức năm, hiển thị biểu đồ cột theo năm.
Drill-down	`drilldown_by_month(year)`	Chọn một năm (`st.selectbox`), xem chi tiết doanh thu theo quý và tháng của năm đó.
Slice	`slice_by_category(year)`	Cố định chiều thời gian ở một năm được chọn, xem doanh thu theo danh mục sản phẩm.
Dice	`dice_states_categories(states, categories, year)`	Chọn nhiều bang và nhiều danh mục (`st.multiselect`) cùng lúc, có thể chọn thêm năm, trả về khối con.
Pivot	`pivot_category_by_year()`	Xoay chiều năm thành cột (`y2016`, `y2017`, `y2018`, `total`) bằng biểu thức `SUM(CASE WHEN…)`, hiển thị dạng bảng.

2.5 Trang 5 – Dự báo & DSS (`page_dss`)

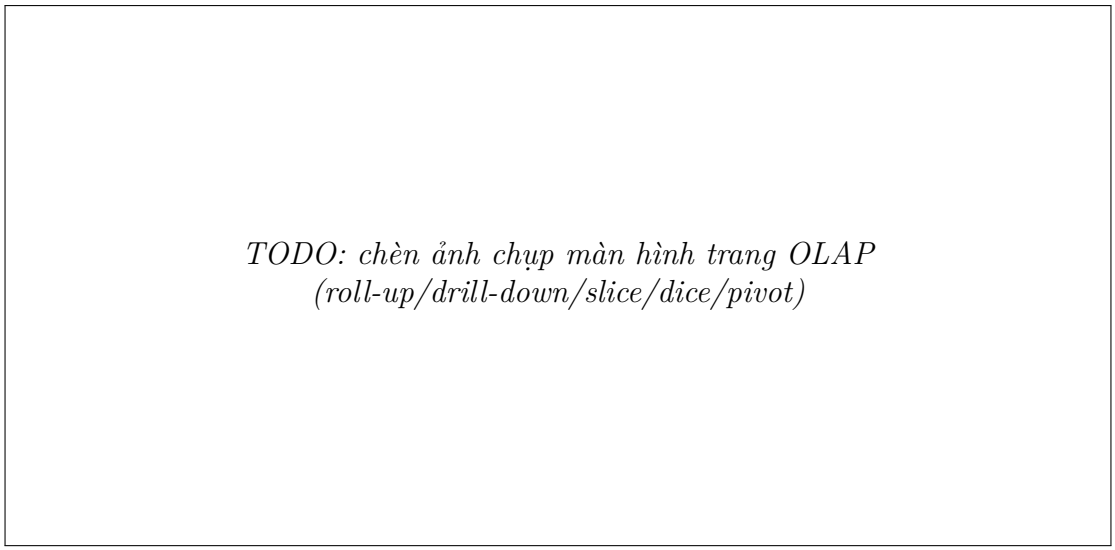
Gồm ba khối tương ứng ba mô hình DSS trình bày ở Mục 3: biểu đồ dự báo doanh thu kèm bảng MAE/MAPE, bảng phân khúc khách hàng RFM + K-Means kèm biểu đồ elbow, và hai khối what-if (giao trễ, khuyến mãi) với thanh trượt tương tác (`st.slider`).

3 Mô hình DSS

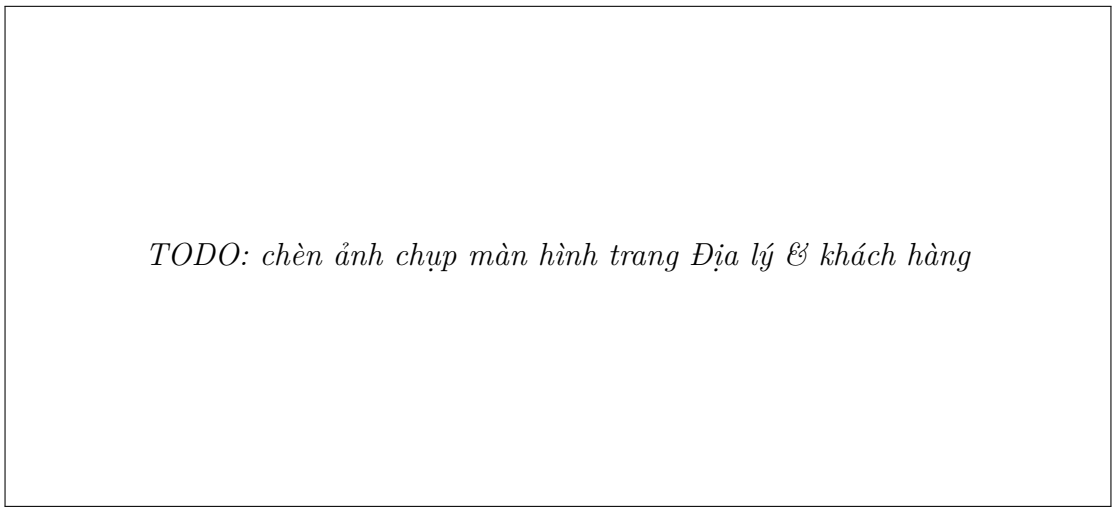
Ba mô-đun trong `src/dss/` đều tuân thủ hợp đồng dữ liệu: chỉ nhận dữ liệu đầu vào từ `src/app/queries.py`, không tự mở kết nối CSDL khác. Số liệu dưới đây lấy từ kết quả chạy thực tế (`python src/dss/forecast.py`, `rfm.py`, `whatif.py`) trên kho dữ liệu đã nạp.

3.1 Dự báo doanh thu (`src/dss/forecast.py`)

Dữ liệu vào. Chuỗi doanh thu theo tháng, 20 điểm từ `2017-01` đến `2018-08` (`monthly_revenue_series_fo`
Khoảng thời gian này được cắt có chủ đích: năm 2016 chỉ có 3 tháng rời rạc và tháng 9/2018 chỉ có 1 đơn, đưa vào sẽ làm nhiễu mô hình.



Hình 3: Trang Phân tích đa chiều (OLAP)



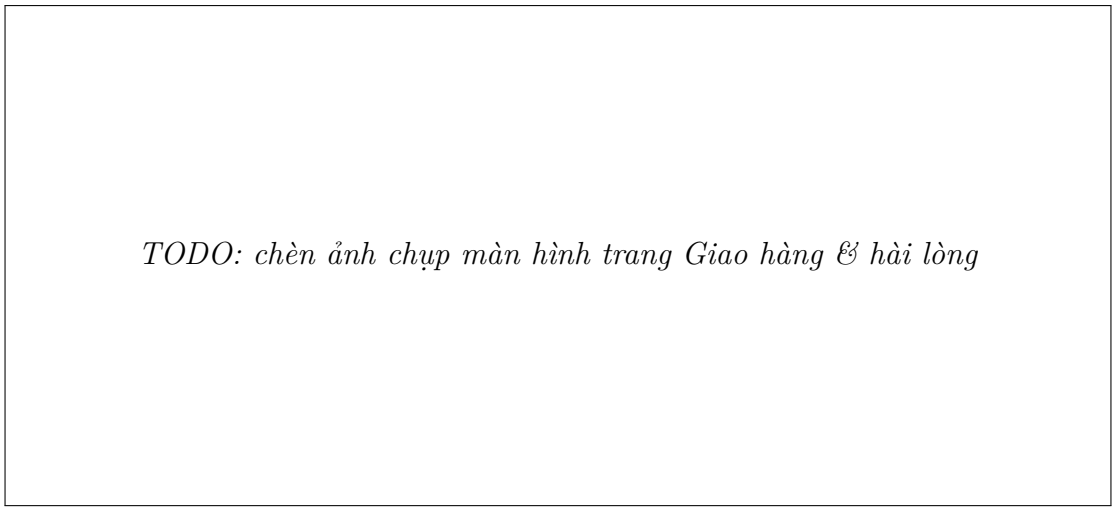
Hình 4: Trang Địa lý & khách hàng

Phương pháp. Giữ lại 4 tháng cuối (`2018-05..2018-08`) làm tập kiểm tra, 16 tháng đầu làm tập huấn luyện (`TEST_SIZE = 4`). So sánh hai mô hình:

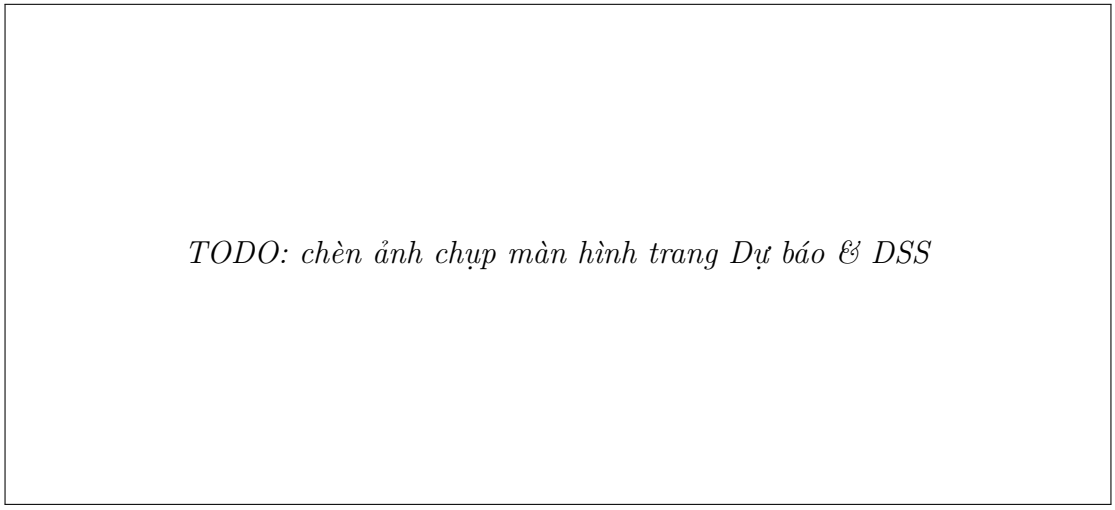
- **Baseline (trung bình trượt):** dự báo phẳng, bằng trung bình 3 tháng cuối của tập huấn luyện, lặp lại cho toàn bộ chân trời dự báo (`_naive_moving_average_forecast`, `window=3`).
- **Holt (xu hướng tuyến tính):** `statsmodels.tsa.holtwinters.ExponentialSmoothing` với `trend="add"`, `seasonal=None` – *không* có thành phần mùa vụ vì chuỗi quá ngắn để ước lượng đáng tin cậy. Mô hình được huấn luyện lại trên toàn bộ 20 tháng để cho ra dự báo 1 bước kế tiếp, kèm khoảng tin cậy 95% tính từ độ lệch chuẩn phần dư (`resid_std`).

Kết quả thực tế. (Bảng 2)

Dự báo tháng kế tiếp sau `2018-08` (mô hình Holt, huấn luyện lại trên toàn bộ chuỗi):



Hình 5: Trang Giao hàng & hài lòng



Hình 6: Trang Dự báo & DSS

854.929,55, khoảng tin cậy 95%: **643.623,52 .. 1.066.235,57**.

Giải thích vì sao Holt tệ hơn baseline. Đúng như cảnh báo trong docstring của mô-đun: doanh thu tăng gần như liên tục rồi đạt đỉnh tại tháng 11/2017 (Black Friday, khoảng 1,0 triệu, xem phần A), sau đó *chững lại và giảm nhẹ*. Mô hình Holt ước lượng một xu hướng tăng tuyến tính từ 16 tháng huấn luyện (kết thúc ở `2018-04`, thời điểm doanh thu vẫn đang hồi phục sau Tết), nên ngoại suy vượt quá doanh thu thực tế của 4 tháng kiểm tra tiếp theo – trong khi baseline (trung bình trượt phẳng) tình cờ bám sát mức doanh thu tương đối ổn định của giai đoạn này hơn. Đây không phải lỗi cài đặt mà là hệ quả trực tiếp của chuỗi thời gian ngắn, chưa đủ 2 chu kỳ mùa vụ để mô hình xu hướng được kiểm chứng đáng tin cậy.

Bảng 2: Sai số dự báo trên tập kiểm tra (4 tháng 2018-05..2018-08)

Mô hình	MAE	MAPE (%)
Baseline (trung bình trượt)	69.432,04	7,85
Holt (xu hướng tuyến tính)	281.179,04	32,24

3.2 Phân khúc khách hàng RFM + K-Means (`src/dss/rfm.py`)

Cái bẫy F (Frequency) và cách xử lý. Trong 95.420 khách hàng (theo `customer_key` đã gộp theo người thật), chỉ khoảng 2.913 người (~3%) có từ 2 đơn trở lên. Vì vậy Frequency theo cách tính kinh điển gần như luôn bằng 1 và không thể chia phân vị (`qcut`) một cách có ý nghĩa. Giải pháp của mô-đun: thay F bằng hai đặc trưng khác – **`repeat_flag`** (cờ nhị phân: 1 nếu khách có ≥ 2 đơn, ngược lại 0) và **`avg_review`** (điểm đánh giá trung bình của khách), vì điểm đánh giá mang tín hiệu hành vi thật mà một cột tần suất luôn bằng 1 không thể cung cấp.

Dữ liệu vào và đặc trưng. Từ `customer_order_history()` (1 dòng / đơn hàng), gộp theo `customer_key` thành 4 đặc trưng: `recency_days` (số ngày từ lần mua gần nhất đến ngày tham chiếu **2018-09-03**, một tháng sau đơn cuối trong cửa sổ phân tích), `monetary` (tổng chi tiêu), `repeat_flag`, `avg_review` (NULL được điền bằng trung vị của khách khác). Dữ liệu được chuẩn hóa bằng `StandardScaler` trước khi phân cụm.

Chọn K. Chạy K-Means với $K \in [2, 6]$, 10 lần khởi tạo mỗi K (`n_init=10`). Vì `silhouette_score` có độ phức tạp $O(n^2)$, tính trên mẫu con 5.000 khách hàng. Kết quả (Bảng 3): K=2 có silhouette cao nhất (0,681) nhưng mô-đun giới hạn lựa chọn trong khoảng 3–4 theo yêu cầu đề bài (`chosen_k = max(3, min(4, chosen_k))`) để có đủ số phân khúc cho hành động nghiệp vụ; trong khoảng đó K=3 có silhouette tốt nhất.

Bảng 3: Inertia và silhouette theo K

K	Inertia	Silhouette
2	283.974,6	0,681
3	208.709,2	0,411
4	153.541,4	0,399
5	108.683,3	0,422
6	95.277,0	0,430

K đã chọn: 3, silhouette = 0,411.

Hồ sơ phân khúc. (Bảng 4) Việc đặt tên phân khúc theo thứ tự ưu tiên trong `_name_segments`: cụm có tỷ lệ mua lại cao nhất (và chi tiêu cao nhất) được gọi là *Khách giá trị cao*; trong các cụm còn lại (chủ yếu khách mua 1 lần, nơi recency/monetary gần

như không khác biệt – chính `avg_review` là yếu tố phân tách), cụm có điểm đánh giá cao nhất là *Khách mới* (hài lòng ở đơn đầu, đáng để chăm sóc cho đơn thứ hai), cụm có điểm đánh giá thấp nhất là *Khách ngủ đông*.

Bảng 4: Hồ sơ từng phân khúc khách hàng

Phân khúc	Recency (ngày)	Monetary	Repeat flag	Review TB	Số khách	%
Khách ngủ đông	248,5	149,5	0,000	1,89	20.300	21,4
Khách mới	242,5	134,8	0,000	4,75	71.792	75,6
Khách giá trị cao	226,6	271,1	0,999	4,17	2.891	3,0

Nhóm *Khách giá trị cao* (3,0% khách hàng) gần như trùng khít với nhóm khách mua lại (`repeat_flag` trung bình 0,999) và có chi tiêu cao nhất. Hai nhóm còn lại đều là khách mua 1 lần (repeat_flag = 0) nhưng tách biệt rõ theo mức độ hài lòng: *Khách mới* hài lòng (4,75/5, chiếm 75,6% khách hàng) trong khi *Khách ngủ đông* không hài lòng (1,89/5, 21,4%).

Hành động đề xuất. Khách giá trị cao: chăm sóc VIP, ưu đãi độc quyền, giao hàng ưu tiên. Khách mới: gửi voucher cho đơn thứ 2, gợi ý sản phẩm liên quan để biến thành khách mua lại. Khách ngủ đông: khảo sát lý do không hài lòng, chiến dịch win-back/giảm giá để tránh mất khách vĩnh viễn.

3.3 Mô hình what-if (`src/dss/whatif.py`)

Mô-đun cung cấp hai mô hình có **tình trạng tri thức (epistemic status) khác nhau**, phải được phân biệt rõ trên giao diện và trong báo cáo.

What-if 1: Giảm giao trễ → điểm hài lòng – dựa trên số đo thực tế. Dựa trên quan hệ *đã đo được* trong DW (phần A, Bảng giao trễ): đơn giao trễ có điểm đánh giá trung bình **2,55**, đơn đúng hạn/sớm **4,21**. Mô hình giả định hai điểm trung bình này không đổi, chỉ tỷ trọng hai nhóm thay đổi, rồi tính trung bình có trọng số (`weighted_avg = p*2.55 + (1-p)*4.21`). Đây là phép nội suy tuyến tính đơn giản, *không phải* mô hình nhân quả đầy đủ. Tỷ lệ giao trễ hiện tại trên dữ liệu: **7,91%**. Ví dụ kết quả (Bảng 5).

Bảng 5: What-if giảm tỷ lệ giao trễ (hiện tại: 7,91%)

Tỷ lệ trễ mục tiêu (%)	Điểm TB dự kiến	Δ so với hiện tại
7,91 (hiện tại)	4,079	+0,000
4,91	4,128	+0,050
1,91	4,178	+0,100
0,00	4,210	+0,131

What-if 2: Khuyến mãi theo danh mục → doanh thu – dựa trên giả định người dùng. Người dùng nhập mức giảm giá (`discount_pct`) và **độ co giãn cầu theo giá** (`elasticity`, quy ước dương = cầu tăng khi giá giảm). Công thức: $\%\Delta\text{quantity} = \text{elasticity} \times \%\Delta(-\text{price})$, từ đó $\text{Revenue}_{new} = \text{Revenue}_{base} \times (1-d) \times (1+\text{elasticity} \times d)$ với d là mức giảm giá. **Độ co giãn là giả định do người dùng tự đặt, không phải số đo thực tế hay dự báo chắc chắn**; giao diện luôn hiển thị cảnh báo này. Ví dụ với danh mục `health_beauty` (doanh thu nền: 1.255.695,00, Bảng 6):

Bảng 6: What-if khuyến mãi – danh mục health_beauty

Giảm giá (%)	Co giãn	Doanh thu dự kiến	Δ (%)
10	1,0	1.243.138	−1,00
10	2,0	1.356.151	+8,00
20	1,5	1.305.923	+4,00

Với co giãn = 1,0 (cầu tăng đúng bằng % giảm giá), doanh thu vẫn giảm nhẹ vì phần tăng số lượng không bù đủ phần giảm giá trên từng đơn vị; cần co giãn > 1 (cầu nhạy hơn giá) thì khuyến mãi mới làm tăng doanh thu trong mô hình này.

4 Đánh giá

Bảng 7: Tổng hợp chỉ số đánh giá các mô hình DSS

Mô hình	Chỉ số	Giá trị
Dự báo – Baseline	MAE / MAPE	69.432,04 / 7,85%
Dự báo – Holt	MAE / MAPE	281.179,04 / 32,24% (kém hơn baseline)
RFM – K-Means	K đã chọn / Silhouette	3 / 0,411
What-if giao trễ	Căn cứ	Số đo thực tế (2,55 vs 4,21)
What-if khuyến mãi	Căn cứ	Giả định người dùng (độ co giãn)

Hạn chế của từng mô hình (nêu trung thực, không phóng đại kết quả).

- **Dự báo doanh thu.** Chuỗi chỉ có 20 tháng, chưa đủ 2 chu kỳ mùa vụ (24 tháng trở lên) nên không thể ước lượng và kiểm chứng một mô hình mùa vụ đáng tin cậy; vì vậy nhóm không dùng Holt-Winters đầy đủ mà chỉ dùng Holt không mùa vụ. Trên dữ liệu hiện tại, Holt có sai số *cao hơn* baseline vì xu hướng tăng ước lượng từ giai đoạn huấn luyện không còn đúng ở giai đoạn kiểm tra (doanh thu chững lại sau đỉnh Black Friday 11/2017). Khoảng tin cậy 95% của dự báo tháng kế tiếp khá rộng (643.623,52 – 1.066.235,57), phản ánh đúng mức độ bất định với chuỗi ngắn.
- **RFM + K-Means.** Silhouette 0,411 ở K=3 là mức *trung bình*, không phải phân cụm tách biệt rõ ràng; K=2 có silhouette cao hơn (0,681) nhưng bị giới hạn lại trong

khoảng 3–4 theo yêu cầu đề bài để có đủ phân khúc hành động. F (Frequency) đã được thay bằng cờ nhị phân mua lại + điểm đánh giá trung bình vì ~97% khách hàng chỉ có 1 đơn, nên đây không phải RFM kinh điển mà là một biến thể phù hợp với đặc điểm dữ liệu.

- **What-if giao trễ.** Giả định điểm trung bình của mỗi nhóm (trễ/đúng hạn) không đổi khi tỷ trọng thay đổi – là một phép nội suy, không phải mô hình nhân quả (không loại trừ các yếu tố gây nhiễu khác ảnh hưởng đến điểm đánh giá).
- **What-if khuyến mãi.** Độ co giãn cầu theo giá là tham số *người dùng tự nhập*, chưa được ước lượng từ dữ liệu lịch sử (DW không có đủ các đợt khuyến mãi có ghi nhận giá gốc/giá giảm để ước lượng co giãn thực tế). Kết quả chỉ mang tính minh họa kịch bản, không phải dự báo.

5 Hạn chế và hướng phát triển

5.1 Hạn chế hiện tại

- **Chưa có ảnh chụp màn hình dashboard.** Báo cáo này dùng khung `\fbox` làm chỗ trống (TODO) cho 5 trang dashboard; cần chụp và chèn ảnh thật trước khi nộp/thuyết trình.
- **Chuỗi thời gian ngắn.** 20 tháng dữ liệu không đủ để kiểm định mô hình mùa vụ hoặc các mô hình dự báo phức tạp hơn (ARIMA mùa vụ, Prophet…).
- **Mô hình Holt hiện đang kém hơn baseline** trên tập kiểm tra 4 tháng cuối – là một kết quả thật, không phải lỗi cài đặt, nhưng cho thấy cần thận trọng khi dùng Holt để ra quyết định thực tế ở giai đoạn dữ liệu hiện tại.
- **F (Frequency) trong RFM bị thay thế** bằng cờ nhị phân mua lại vì đặc thù dữ liệu (hầu hết khách chỉ mua 1 lần trong giai đoạn quan sát), nên các phân khúc không hoàn toàn tương đương RFM kinh điển.
- **Độ co giãn cầu trong what-if khuyến mãi** là tham số giả định, chưa được kiểm chứng bằng dữ liệu thực nghiệm (A/B test hay lịch sử khuyến mãi).

5.2 Hướng phát triển

1. Thu thập/tích lũy thêm dữ liệu theo thời gian để chuỗi doanh thu đạt tối thiểu 24 tháng, cho phép dùng Holt-Winters có thành phần mùa vụ và so sánh với các mô hình như SARIMA hoặc Prophet.
2. Ghi nhận các đợt khuyến mãi thực tế (giá gốc, giá giảm, doanh số trước/sau) để ước lượng độ co giãn cầu theo giá từ dữ liệu thay vì để người dùng tự giả định.
3. Bổ sung ảnh chụp màn hình và video demo thực tế cho từng trang dashboard; cân nhắc thêm bản đồ theo mã bưu chính nếu phần A mở rộng dùng dữ liệu địa lý chi tiết.