BÁO CÁO BÀI TẬP LỚN CO4031

Kho dữ liệu thương mại điện tử Olist và hệ hỗ trợ ra quyết định

Phần A: Kho dữ liệu, ETL và OLAP | Phần B: Dashboard và DSS

Người A (Data & DW): tamnguyen635
Người B (Ứng dụng & DSS): Vỹ

Học kỳ 261 – Năm học 2026–2027

Mục lục

I Kho dữ liệu, ETL và OLAP **3**

1 Giới thiệu và phân tích yêu cầu nghiệp vụ **3**
1.1 Bối cảnh bài toán . . . 3
1.2 Đối tượng sử dụng và câu hỏi nghiệp vụ . . . 3
1.3 Nguồn dữ liệu . . . 3
1.4 Kết quả khảo sát chất lượng dữ liệu . . . 4

2 Thiết kế kho dữ liệu **4**
2.1 Kiến trúc tổng thể . . . 4
2.2 Lựa chọn phương pháp và công nghệ . . . 5
2.3 Mức hạt (granularity) . . . 5
2.4 Mô hình dữ liệu đa chiều . . . 5
2.5 Các quyết định thiết kế quan trọng . . . 5
2.6 Đối chiếu với đặc trưng của kho dữ liệu . . . 7

3 Quy trình ETL **7**
3.1 Extract . . . 7
3.2 Transform . . . 8
3.3 Load . . . 8
3.4 Kiểm tra chất lượng dữ liệu . . . 8

4 Phân tích đa chiều (OLAP) 8
4.1 Roll-up: từ tháng lên năm . . . 9
4.2 Drill-down: từ năm 2017 xuống quý và tháng . . . 9
4.3 Slice: cố định năm 2017, xem theo danh mục . . . 10
4.4 Dice: khối con theo bang, năm và danh mục . . . 10
4.5 Pivot: danh mục theo năm . . . 10
4.6 Các truy vấn phân tích bổ sung . . . 10

5 Hạn chế và hướng phát triển của phần kho dữ liệu 11

II Dashboard phân tích và Hệ hỗ trợ ra quyết định (DSS) 13

6 Kiến trúc dashboard và DSS 13
6.1 Vị trí trong hệ thống . . . 13
6.2 Các tầng . . . 13

7 Dashboard Streamlit 14
7.1 Trang 1 – Tổng quan (`page_overview`) . . . 14
7.2 Trang 2 – Phân tích đa chiều (OLAP) (`page_olap`) . . . 14
7.3 Trang 3 – Địa lý & khách hàng (`page_geo_customer`) . . . 15
7.4 Trang 4 – Giao hàng & hài lòng (`page_delivery`) . . . 15
7.5 Trang 5 – Dự báo & DSS (`page_dss`) . . . 15

8 Mô hình DSS 16
8.1 Dự báo doanh thu (`src/dss/forecast.py`) . . . 16
8.2 Phân khúc khách hàng RFM + K-Means (`src/dss/rfm.py`) . . . 18
8.3 Mô hình what-if (`src/dss/whatif.py`) . . . 19

9 Đánh giá 20

10 Hạn chế và hướng phát triển 21
10.1 Hạn chế hiện tại . . . 21
10.2 Hướng phát triển . . . 22

Part I

Kho dữ liệu, ETL và OLAP

1 Giới thiệu và phân tích yêu cầu nghiệp vụ

1.1 Bối cảnh bài toán

Thương mại điện tử sinh ra lượng dữ liệu giao dịch rất lớn: mỗi đơn hàng gắn với khách hàng, người bán, sản phẩm, hình thức thanh toán, thời gian giao hàng và đánh giá sau mua. Các hệ thống tác nghiệp (OLTP) lưu những dữ liệu này theo dạng chuẩn hóa để xử lý giao dịch nhanh, nhưng *không* thuận tiện cho việc phân tích tổng hợp theo nhiều chiều (thời gian, vùng, danh mục…). Vì vậy cần một kho dữ liệu (Data Warehouse – DW) tích hợp dữ liệu lịch sử và một hệ hỗ trợ quyết định (DSS) khai thác kho đó.

Nhóm chọn lĩnh vực **bán lẻ / thương mại điện tử**, dùng bộ dữ liệu công khai *Brazilian E-Commerce Public Dataset by Olist* (Kaggle) [3]. Bộ dữ liệu gồm khoảng 100 nghìn đơn hàng thật đã được ẩn danh, từ 04/09/2016 đến 17/10/2018 (các dòng hàng có giá trị chỉ kéo dài đến 03/09/2018), đáp ứng yêu cầu về quy mô và ý nghĩa thực tế của đề bài.

1.2 Đối tượng sử dụng và câu hỏi nghiệp vụ

Kho dữ liệu phục vụ ban quản lý của một sàn thương mại điện tử (quản lý kinh doanh, vận hành, chăm sóc khách hàng). Các câu hỏi nghiệp vụ chính mà phần DW phải trả lời được:

1. Doanh thu thay đổi thế nào theo năm, quý, tháng? Thời điểm nào là cao điểm?
2. Danh mục sản phẩm nào đóng góp nhiều doanh thu nhất, và xu hướng của chúng qua các năm ra sao?
3. Doanh thu và mức độ hài lòng của khách phân bố theo bang/vùng như thế nào?
4. Khách hàng thanh toán bằng hình thức nào, có trả góp hay không?
5. Giao hàng trễ ảnh hưởng thế nào đến điểm đánh giá của khách?

Các câu hỏi này là đầu vào cho thành phần DSS (phần B): dự báo doanh thu, phân khúc khách hàng và mô hình what-if cho vận hành.

1.3 Nguồn dữ liệu

Dữ liệu nguồn gồm 8 tệp CSV có quan hệ với nhau, mô phỏng một cơ sở dữ liệu tác nghiệp (Bảng 1). Tệp `olist_geolocation_dataset` (khoảng 1 triệu dòng tọa độ theo mã bưu chính) không được dùng vì thành phố, bang và mã bưu chính đã có sẵn trong tệp khách hàng và người bán, đủ cho các phân tích theo địa lý.

Bảng 1: Các tệp dữ liệu nguồn

Tệp	Số dòng	Nội dung chính
`olist_orders`	99.441	Đơn hàng: trạng thái, ngày mua, ngày giao thực tế, ngày giao dự kiến
`olist_order_items`	112.650	Từng sản phẩm trong đơn: sản phẩm, người bán, giá, phí vận chuyển
`olist_customers`	99.441	Khách hàng: mã khách, thành phố, bang, mã bưu chính
`olist_products`	32.951	Sản phẩm: danh mục, kích thước, cân nặng, số ảnh
`olist_sellers`	3.095	Người bán: thành phố, bang
`olist_order_payments`	103.886	Thanh toán: hình thức, số kỳ trả góp, số tiền
`olist_order_reviews`	99.224	Đánh giá: điểm 1–5, bình luận
`product_category_name_translation`	71	Dịch tên danh mục từ tiếng Bồ Đào Nha sang tiếng Anh

1.4 Kết quả khảo sát chất lượng dữ liệu

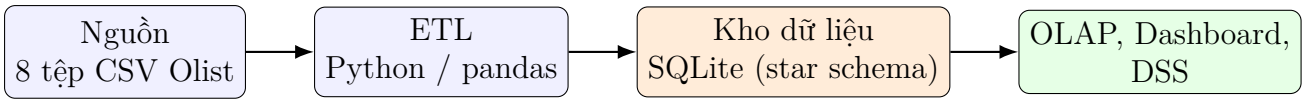
Trước khi thiết kế, nhóm khảo sát toàn bộ 8 tệp. Những phát hiện ảnh hưởng trực tiếp đến thiết kế và ETL:

- Khóa tham chiếu *toàn vẹn*: mọi `order_id`, `product_id`, `seller_id`, `customer_id` trong bảng chi tiết đơn đều tồn tại ở bảng gốc.
- `customer_id` *thay đổi theo từng đơn hàng*; người mua thật được xác định bằng `customer_unique_id` (96.096 người trên 99.441 mã).
- 775 đơn hàng không có sản phẩm nào (chủ yếu đơn đã hủy hoặc chưa hoàn tất).
- 2.246 đơn thanh toán bằng nhiều hình thức; 547 đơn có nhiều hơn một đánh giá; 1 đơn không có thanh toán.
- 610 sản phẩm không có danh mục; 2 danh mục (`pc_gamer`, bếp di động) thiếu bản dịch.
- Giá trị thiếu hợp lý về nghiệp vụ: đơn chưa giao thì chưa có ngày giao; nhiều đơn không có bình luận.
- 8 đơn ở trạng thái *delivered* nhưng thiếu ngày giao; 6 đơn chưa ở trạng thái *delivered* nhưng đã có ngày giao.

2 Thiết kế kho dữ liệu

2.1 Kiến trúc tổng thể

Hệ thống theo kiến trúc ba tầng của kho dữ liệu: tầng nguồn (CSV), tầng tích hợp/ETL và tầng kho dữ liệu đa chiều, trên đó là tầng trình bày (OLAP, dashboard, DSS). Hình 1 minh họa luồng dữ liệu.



Hình 1: Luồng dữ liệu của hệ thống

2.2 Lựa chọn phương pháp và công nghệ

Theo hai trường phái kinh điển, Inmon xây kho dữ liệu doanh nghiệp (EDW) chuẩn hóa trước rồi tách ra các data mart (top-down), còn Kimball xây từng data mart theo mô hình chiều rồi hợp nhất dần (bottom-up) [2, 1]. Nhóm chọn **hướng Kimball với một data mart cho chủ đề bán hàng**, vì: (i) bài toán có phạm vi một quy trình nghiệp vụ rõ ràng (bán hàng); (ii) thời gian thực hiện ngắn, cần giá trị sử dụng sớm; (iii) mô hình chiều dạng sao tối ưu cho truy vấn tổng hợp và dễ hiểu với người dùng nghiệp vụ.

Về công nghệ, nhóm dùng **SQLite** làm hệ quản trị lưu kho, theo kiểu **ROLAP**: các phép OLAP được thực hiện bằng truy vấn SQL trên lược đồ quan hệ, không dựng khối dữ liệu (cube) được tính trước như MOLAP. SQLite gọn, chạy cục bộ và đủ nhanh cho khoảng 112 nghìn dòng fact.

2.3 Mức hạt (granularity)

Mức hạt của bảng fact là **một dòng cho mỗi sản phẩm trong một đơn hàng** (`order_id` + `order_item_id`). Đây là mức chi tiết nhất có sẵn trong nguồn: từ đó có thể cộng dồn lên theo đơn, theo ngày, theo danh mục, theo bang…mà không mất thông tin. Chọn mức hạt thấp hơn (ví dụ gộp theo đơn) sẽ làm mất khả năng phân tích theo sản phẩm và người bán, vì một đơn có thể chứa nhiều sản phẩm từ nhiều người bán khác nhau. Chi phí là số dòng fact lớn hơn, nhưng với quy mô này vẫn chấp nhận được.

2.4 Mô hình dữ liệu đa chiều

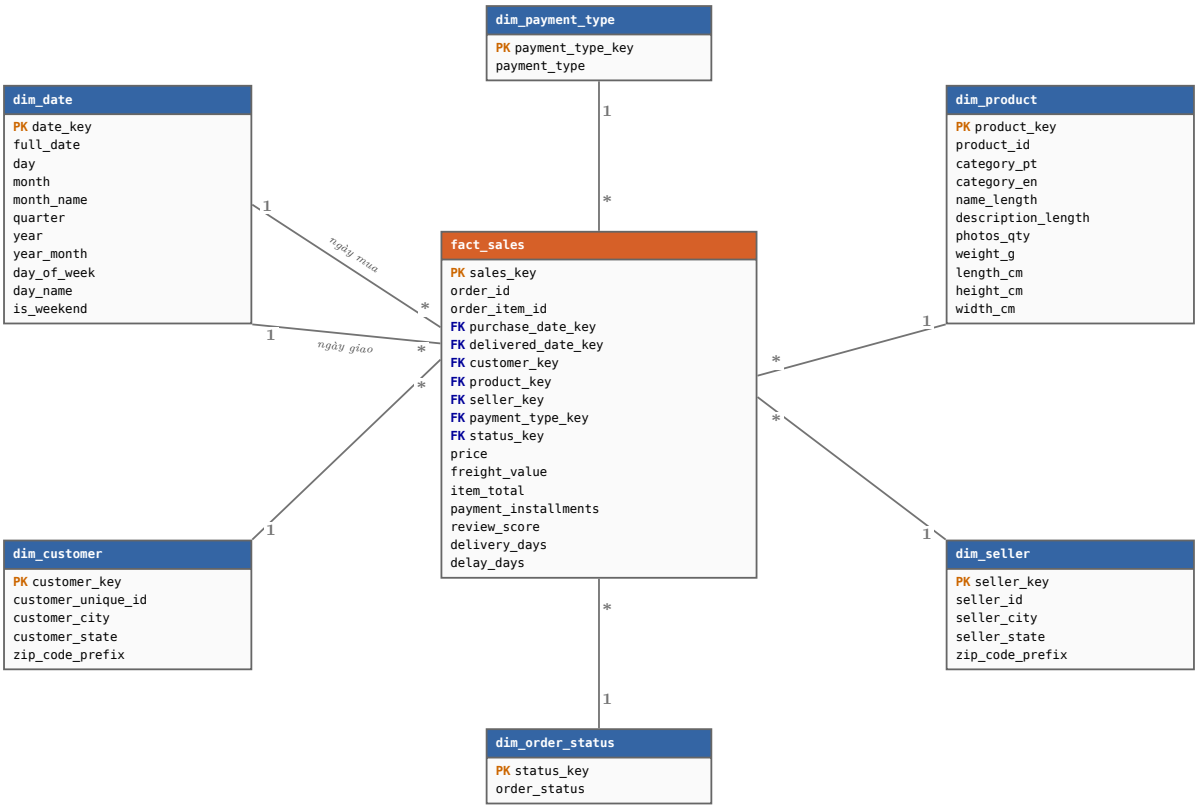
Lược đồ là **star schema** gồm một bảng fact `fact_sales` và sáu bảng chiều (Hình 2).

Bảng fact `fact_sales`. Chứa khóa ngoại tới các chiều, một chiều suy biến (`order_id`) và các độ đo (Bảng 2).

Các bảng chiều. Bảng 3 liệt kê các chiều cùng phân cấp (hierarchy) hỗ trợ roll-up và drill-down.

2.5 Các quyết định thiết kế quan trọng

D1. Khóa thay thế (surrogate key). Mọi chiều dùng khóa số nguyên tự sinh, tách biệt khỏi khóa nghiệp vụ, giúp join nhanh và độc lập với thay đổi ở nguồn. Riêng `dim_date` dùng khóa dạng `yyyymmdd` để dễ đọc và lọc theo khoảng thời gian.



Hình 2: Star schema của kho dữ liệu bán hàng Olist

D2. Khách hàng theo người thật. `dim_customer` lấy `customer_unique_id` làm khóa nghiệp vụ. Nếu dùng `customer_id` thì cùng một người sẽ bị đếm nhiều lần, làm sai các phép đếm khách và phân khúc ở phần DSS. Khi một người xuất hiện với nhiều địa chỉ, giữ địa chỉ của đơn gần nhất.

D3. Chiều ngày dùng hai lần (role-playing). `dim_date` được tham chiếu bởi cả ngày mua và ngày giao, nhờ đó không cần hai bảng lịch riêng.

D4. Hình thức thanh toán chính. Một đơn có thể trả bằng nhiều cách. Để giữ mức hạt của fact, nhóm chọn hình thức có số tiền lớn nhất làm hình thức chính của đơn (2.246 đơn bị ảnh hưởng). Hạn chế này được nêu ở mục hạn chế.

D5. Điểm đánh giá theo đơn. Với đơn có nhiều đánh giá, lấy trung bình; đơn không có đánh giá giữ NULL thay vì điền số giả, để các phép AVG không bị lệch.

D6. Chiều trạng thái đơn. Giữ cả đơn hủy và chưa hoàn tất trong fact và lọc theo trạng thái khi truy vấn, thay vì xóa khỏi kho, để bảo toàn lịch sử (đặc tính không thay đổi của DW) và cho phép phân tích tỷ lệ hủy.

D7. Không dùng chiều chậm thay đổi (SCD). Dữ liệu nguồn là ảnh chụp tại một thời điểm, không có lịch sử thay đổi thuộc tính khách hàng hay sản phẩm, nên các chiều được xử lý theo SCD loại 1.

Bảng 2: Các cột của bảng fact

Cột	Loại	Ý nghĩa
`order_id`, `order_item_id`	Chiều suy biến	Định danh đơn và dòng hàng, không tách thành bảng chiều riêng
`purchase_date_key`	Khóa ngoại	Ngày mua hàng (`dim_date`)
`delivered_date_key`	Khóa ngoại	Ngày giao thực tế, NULL nếu chưa giao
`customer_key`, `product_key`, `seller_key`	Khóa ngoại	Khách hàng, sản phẩm, người bán
`payment_type_key`, `status_key`	Khóa ngoại	Hình thức thanh toán chính, trạng thái đơn
`price`, `freight_value`	Độ đo (cộng được)	Giá bán và phí vận chuyển
`item_total`	Độ đo (cộng được)	Giá + phí vận chuyển
`payment_installments`	Độ đo (không cộng)	Số kỳ trả góp của hình thức thanh toán chính
`review_score`	Độ đo (bán cộng)	Điểm đánh giá trung bình của đơn (1–5)
`delivery_days`	Độ đo (bán cộng)	Số ngày từ lúc mua đến lúc giao
`delay_days`	Độ đo (bán cộng)	Giao thực tế trừ dự kiến; lớn hơn 0 nghĩa là giao trễ

2.6 Đối chiếu với đặc trưng của kho dữ liệu

Kho dữ liệu đáp ứng bốn đặc trưng của Inmon [1]: *hướng chủ đề* (tổ chức quanh chủ đề bán hàng, không theo ứng dụng); *tích hợp* (8 bảng nguồn được hợp nhất, chuẩn hóa tên danh mục, mã khách, định dạng ngày); *biến thiên theo thời gian* (mọi dòng fact gắn với ngày và có chiều lịch đầy đủ); *không thay đổi* (dữ liệu nạp vào được truy vấn chỉ đọc, không sửa).

3 Quy trình ETL

Toàn bộ quy trình được hiện thực trong một tập lệnh Python (`src/etl/run_etl.py`) dùng thư viện pandas và `sqlite3`, chạy một lệnh duy nhất và hoàn thành trong khoảng 5 giây.

3.1 Extract

Đọc 8 tệp CSV, *tất cả ở dạng chuỗi*. Việc này giữ nguyên các mã bưu chính có số 0 đứng đầu (nếu đọc thành số sẽ mất số 0 và sai khóa). Tập lệnh kiểm tra đủ tệp trước khi chạy và báo rõ tệp nào còn thiếu.

Bảng 3: Các bảng chiều và phân cấp

Chiều	Số dòng	Thuộc tính chính	Phân cấp
`dim_date`	774	ngày, tháng, quý, năm, thứ, cuối tuần	ngày → tháng → quý → năm
`dim_customer`	96.096	mã khách thật, thành phố, bang, mã bưu chính	thành phố → bang
`dim_product`	32.951	danh mục (BĐN và Anh), kích thước, cân nặng	sản phẩm → danh mục
`dim_seller`	3.095	thành phố, bang, mã bưu chính	thành phố → bang
`dim_payment_type`	5	thẻ tín dụng, boleto, voucher, thẻ ghi nợ…	–
`dim_order_status`	8	delivered, shipped, canceled…	–

3.2 Transform

Bảng 4 tóm tắt các phép biến đổi và lý do.

Việc ghép các bảng được thực hiện bằng phép nối trái từ bảng chi tiết đơn, kèm tổng hợp trước ở mức đơn (thanh toán chính, điểm đánh giá trung bình). Cách này tránh được lỗi nhân đôi dòng thường gặp khi nối trực tiếp các bảng có quan hệ một-nhiều.

3.3 Load

Tập lệnh tạo lược đồ từ tệp `01_schema.sql` (khóa chính, khóa ngoại, chỉ mục trên các khóa ngoại của fact), sau đó nạp các bảng chiều trước, bảng fact sau để thỏa ràng buộc khóa ngoại. Bảng 5 cho thấy số dòng đã nạp.

3.4 Kiểm tra chất lượng dữ liệu

Sau khi nạp, ETL tự chạy các kiểm tra và dừng với thông báo lỗi nếu có kiểm tra thất bại (Bảng 6). Tất cả các kiểm tra đều đạt trên dữ liệu thực tế.

Một số giá trị thiếu được giữ nguyên vì có ý nghĩa nghiệp vụ: 942 dòng fact chưa có điểm đánh giá, 3 dòng không có hình thức thanh toán, và các độ đo giao hàng NULL với đơn chưa giao.

4 Phân tích đa chiều (OLAP)

Các phép OLAP được hiện thực bằng SQL trên star schema (tệp `02_olap_queries.sql`) và chạy bằng `olap_demo.py`. Quy ước: doanh thu là tổng `price`; loại các đơn *canceled* và *unavailable*.

Bảng 4: Các phép biến đổi dữ liệu

Vấn đề	Xử lý	Lý do
Khách trùng người (nhiều `customer_id`)	Gộp về `customer_unique_id`, giữ địa chỉ gần nhất	Đếm đúng số khách thật
Danh mục tiếng Bồ Đào Nha	Dịch sang tiếng Anh; 2 danh mục thiếu bản dịch được dịch thủ công	Báo cáo dễ đọc
Sản phẩm không có danh mục (610)	Gán `unknown`	Không mất dòng fact khi join
Tên cột sai chính tả (`lenght`)	Đổi thành `length`	Thống nhất đặt tên
Nhiều thanh toán trên một đơn	Chọn hình thức có số tiền lớn nhất	Giữ mức hạt của fact
Nhiều đánh giá trên một đơn	Lấy trung bình điểm	Một giá trị cho mỗi đơn
Đơn không có sản phẩm (775)	Loại khỏi fact	Không có doanh thu để ghi nhận
Cột ngày dạng chuỗi	Chuyển sang datetime, sinh khóa `yyyymmdd`	Truy vấn theo thời gian
Độ đo giao hàng	`delivery_days` và `delay_days` tính từ các mốc thời gian	Phân tích hiệu quả vận chuyển
Chiều ngày	Sinh liên tục từ ngày nhỏ nhất đến lớn nhất của dữ liệu	Không có khoảng trống lịch

4.1 Roll-up: từ tháng lên năm

```sql
SELECT d.year, ROUND(SUM(f.price), 2) AS revenue,
       COUNT(DISTINCT f.order_id) AS orders
FROM fact_sales f
JOIN dim_date d         ON f.purchase_date_key = d.date_key
JOIN dim_order_status s ON f.status_key = s.status_key
WHERE s.order_status NOT IN ('canceled', 'unavailable')
GROUP BY d.year ORDER BY d.year;
```

Năm 2016 chỉ có 3 tháng rời rạc (9, 10, 12) và năm 2018 chỉ có dữ liệu từ tháng 1 đến tháng 8 (tháng 9 chỉ có 1 đơn), nên không thể so sánh trực tiếp tổng cả năm; muốn so sánh công bằng cần đối chiếu cùng kỳ tháng 1–8.

4.2 Drill-down: từ năm 2017 xuống quý và tháng

Truy vấn nhóm theo `quarter` và `year_month` của năm 2017. Doanh thu tăng gần như liên tục từ 120 nghìn (tháng 1) lên đỉnh **khoảng 1,0 triệu vào tháng 11/2017**, gần dịp Black Friday (24/11/2017), rồi giảm xuống khoảng 742 nghìn ở tháng 12. Dữ liệu không ghi nhận chương trình khuyến mãi nào, nên mối liên hệ với Black Friday chỉ là suy đoán.

Bảng 5: Số dòng sau khi nạp

Bảng	Số dòng
dim_date	774
dim_customer	96.096
dim_product	32.951
dim_seller	3.095
dim_payment_type	5
dim_order_status	8
fact_sales	112.650

Bảng 6: Các kiểm tra chất lượng sau ETL

Kiểm tra	Kết quả
Số dòng fact bằng số dòng của bảng chi tiết đơn nguồn (112.650)	Đạt
Không có khóa ngoại mồ côi tới dim_customer, dim_product, dim_seller	Đạt
Không có khóa ngoại mồ côi tới dim_date (ngày mua và ngày giao)	Đạt
Không có giá âm	Đạt
item_total = price + freight_value	Đạt

4.3 Slice: cố định năm 2017, xem theo danh mục

Cố định chiều thời gian ở năm 2017, nhóm theo danh mục sản phẩm. Năm danh mục dẫn đầu gồm bed_bath_table (khoảng 498 nghìn), watches_gifts (khoảng 487 nghìn), health_beauty (khoảng 481 nghìn), sports_leisure (khoảng 448 nghìn) và computers_accessories (khoảng 400 nghìn).

4.4 Dice: khối con theo bang, năm và danh mục

Chọn khối con gồm bang SP và RJ, năm 2018, và ba danh mục health_beauty, bed_bath_table, computers_accessories.

4.5 Pivot: danh mục theo năm

Xoay chiều thời gian thành cột để so sánh trực tiếp các năm bằng biểu thức CASE WHEN trong SUM. Danh mục health_beauty dẫn đầu về tổng doanh thu (khoảng 1,26 triệu), tăng từ 481 nghìn (2017) lên 770 nghìn (2018); ngược lại cool_stuff giảm từ 389 nghìn xuống 231 nghìn.

4.6 Các truy vấn phân tích bổ sung

Theo địa lý. Bang SP chiếm khoảng 5,17 triệu trong tổng doanh thu, vượt xa RJ (1,81 triệu) và MG (1,57 triệu). RJ có điểm đánh giá trung bình thấp hơn đáng kể (3,82) so với SP (4,14).

Bảng 7: Doanh thu theo năm

Năm	Doanh thu	Số đơn
2016	44.726,06	293
2017	6.108.492,27	44.375
2018	7.341.182,41	53.531

Bảng 8: Phép dice: doanh thu năm 2018

Bang	Danh mục	Doanh thu
SP	health_beauty	302.498,32
SP	bed_bath_table	270.371,52
SP	computers_accessories	210.549,64
RJ	health_beauty	79.176,36
RJ	bed_bath_table	67.562,26
RJ	computers_accessories	59.658,92

Hình thức thanh toán. Thẻ tín dụng chiếm khoảng 78,9% doanh thu, boleto (phiếu thanh toán Brazil) 17,6%, voucher 2,1% và thẻ ghi nợ 1,4%.

Giao hàng và mức hài lòng. Chênh lệch lớn nhất nằm ở giao hàng (Bảng 9): dòng hàng giao trễ có điểm đánh giá trung bình 2,55, còn giao đúng hạn hoặc sớm là 4,21.

Bảng 9: Giao hàng trễ và điểm đánh giá (đơn đã giao)

Nhóm	Số dòng hàng	Ngày giao TB	Điểm TB
Giao trễ	8.714	31,3	2,55
Đúng hạn hoặc sớm	101.475	10,9	4,21

5 Hạn chế và hướng phát triển của phần kho dữ liệu

- **Một chủ đề duy nhất.** Kho mới có một data mart (bán hàng). Có thể mở rộng thành fact constellation với fact thanh toán, fact đánh giá, dùng chung các chiều.
- **Hình thức thanh toán chính.** Việc chỉ giữ một hình thức cho mỗi đơn làm mất thông tin các đơn trả bằng nhiều cách; có thể bổ sung bảng fact thanh toán riêng ở mức hạt từng lần thanh toán.
- **ROLAP trên SQLite.** Không có khối dữ liệu tính trước; với dữ liệu lớn hơn nên chuyển sang hệ quản trị có hỗ trợ phân vùng và chỉ mục bitmap, hoặc dựng khối MOLAP.
- **ETL nạp toàn bộ.** Mỗi lần chạy tạo lại kho từ đầu. Hướng phát triển là nạp gia tăng (incremental) và ghi lại lịch sử nạp trong metadata.

- **Chưa dùng dữ liệu địa lý chi tiết.** Có thể bổ sung tọa độ theo mã bưu chính (sau khi gộp để giảm dung lượng) để vẽ bản đồ trên dashboard.
- **Phạm vi thời gian.** Dữ liệu không đầy đủ ở hai đầu (2016 chỉ có 3 tháng rời rạc, 2018 dừng ở tháng 8), nên cần thận trọng khi so sánh theo năm.

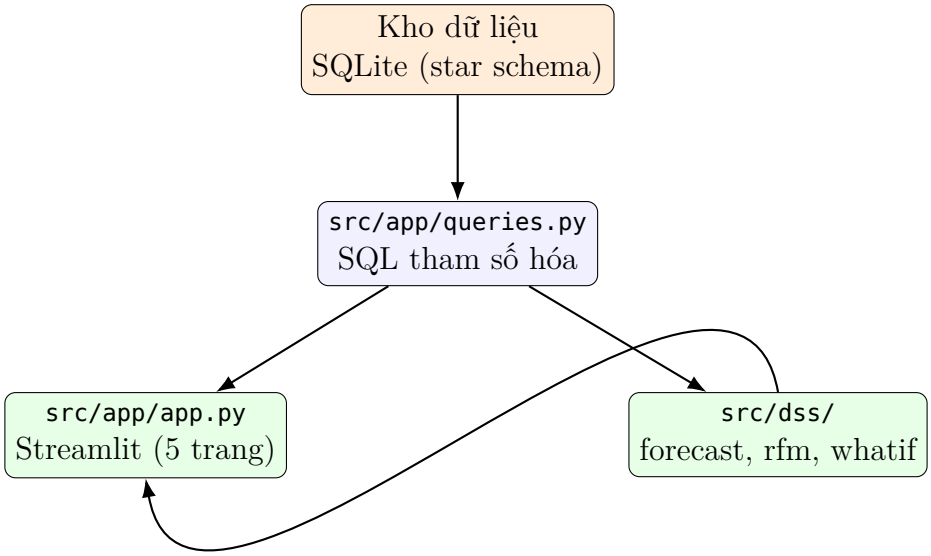
Part II

Dashboard phân tích và Hệ hỗ trợ ra quyết định (DSS)

6 Kiến trúc dashboard và DSS

6.1 Vị trí trong hệ thống

Phần B dùng lại kho dữ liệu (DW) do phần A xây dựng, không đọc lại các tệp CSV gốc. Theo hợp đồng dữ liệu giữa hai phần (`docs/data_contract.md`), phần B *chỉ đọc* từ tệp `data/processed/olist_dw.db` đã được ETL của phần A nạp sẵn theo lược đồ star schema (`src/sql/01_schema.sql`). Phần B không được tự sửa lược đồ hay đọc CSV trực tiếp, để tránh hai phần xung đột dữ liệu.



Hình 3: Kiến trúc dashboard và DSS: giao diện và các mô hình DSS đều chỉ truy cập DW qua một tầng truy vấn SQL duy nhất

6.2 Các tầng

- **Tầng truy vấn (`src/app/queries.py`).** Toàn bộ câu SQL đọc DW nằm trong một tệp duy nhất. Mọi điều kiện lọc (năm, bang, danh mục…) dùng tham số `?` của

`sqlite3`, không nối chuỗi, tránh SQL injection và giữ quy ước doanh thu `SUM(price)`, loại đơn `canceled`/`unavailable` thống nhất ở một chỗ (hàm `_not_canceled_clause`).

- **Tầng giao diện (`src/app/app.py`).** Ứng dụng Streamlit, chỉ gọi hàm ở `queries.py` và ba mô-đun DSS, không bao giờ mở kết nối CSDL trực tiếp. Mỗi hàm truy vấn được bọc bằng `@st.cache_data` để không truy vấn lại DW mỗi lần người dùng tương tác với widget.
- **Tầng DSS (`src/dss/forecast.py`, `rfm.py`, `whatif.py`).** Ba mô-đun độc lập, có thể chạy trực tiếp bằng dòng lệnh (`python src/dss/forecast.py`) để kiểm tra kết quả ngoài giao diện, đồng thời được `app.py` import và gọi lại trong trang *Dự báo & DSS*.

7 Dashboard Streamlit

Dashboard gồm 5 trang, chọn qua `st.sidebar.radio` (hàm `main()` trong `app.py`, biến `PAGES`).

7.1 Trang 1 – Tổng quan (`page_overview`)

Hiển thị 5 chỉ số KPI (doanh thu, số đơn, giá trị đơn trung bình, điểm đánh giá trung bình, % giao trễ) từ `kpi_summary()`, và biểu đồ đường doanh thu theo tháng từ `monthly_revenue()`.

TODO: chèn ảnh chụp màn hình trang Tổng quan

Hình 4: Trang Tổng quan của dashboard

7.2 Trang 2 – Phân tích đa chiều (OLAP) (`page_olap`)

Trang này trình bày năm phép toán OLAP: roll-up, drill-down, slice, dice và pivot. Mỗi phép toán có một hàm riêng trong `queries.py` (Bảng 10).

Bảng 10: Ánh xạ phép toán OLAP sang hàm truy vấn và thành phần giao diện

Phép toán	**Hàm (`queries.py`)**	**Thao tác trên giao diện**
Roll-up	`rollup_by_year()`	Tổng hợp doanh thu từ mức tháng lên mức năm, hiển thị biểu đồ cột theo năm.
Drill-down	`drilldown_by_month(year)`	Chọn một năm (`st.selectbox`), xem chi tiết doanh thu theo quý và tháng của năm đó.
Slice	`slice_by_category(year)`	Cố định chiều thời gian ở một năm được chọn, xem doanh thu theo danh mục sản phẩm.
Dice	`dice_states_categories(states, categories, year)`	Chọn nhiều bang và nhiều danh mục (`st.multiselect`) cùng lúc, có thể chọn thêm năm, trả về khối con.
Pivot	`pivot_category_by_year()`	Xoay chiều năm thành cột (`y2016`, `y2017`, `y2018`, `total`) bằng biểu thức `SUM(CASE WHEN…)`, hiển thị dạng bảng.

7.3 Trang 3 – Địa lý & khách hàng (`page_geo_customer`)

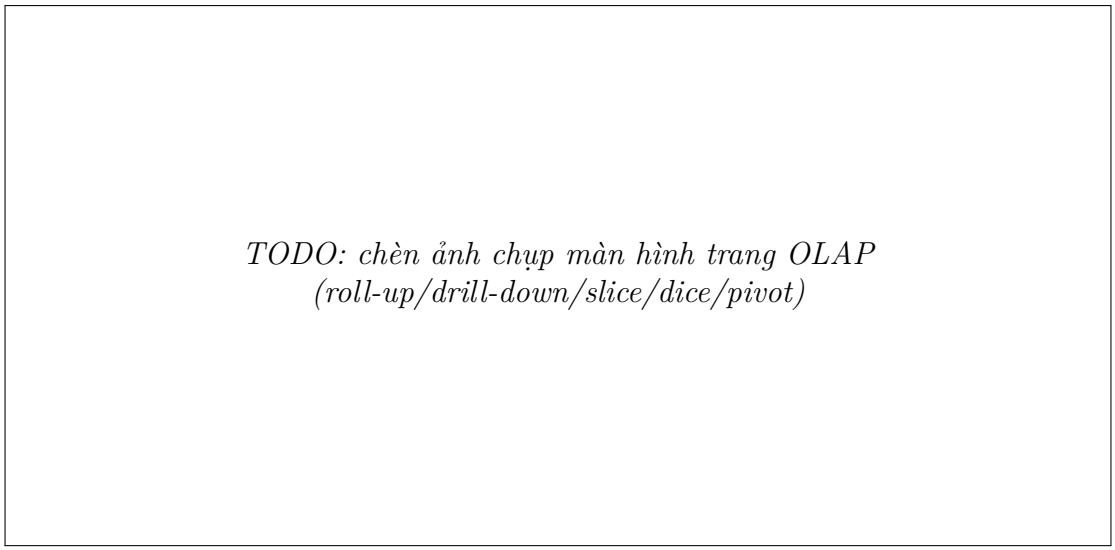
Biểu đồ cột doanh thu theo bang, tô màu theo điểm đánh giá trung bình (`revenue_review_by_state()`), và biểu đồ tròn cơ cấu doanh thu theo hình thức thanh toán (`payment_mix()`).

7.4 Trang 4 – Giao hàng & hài lòng (`page_delivery`)

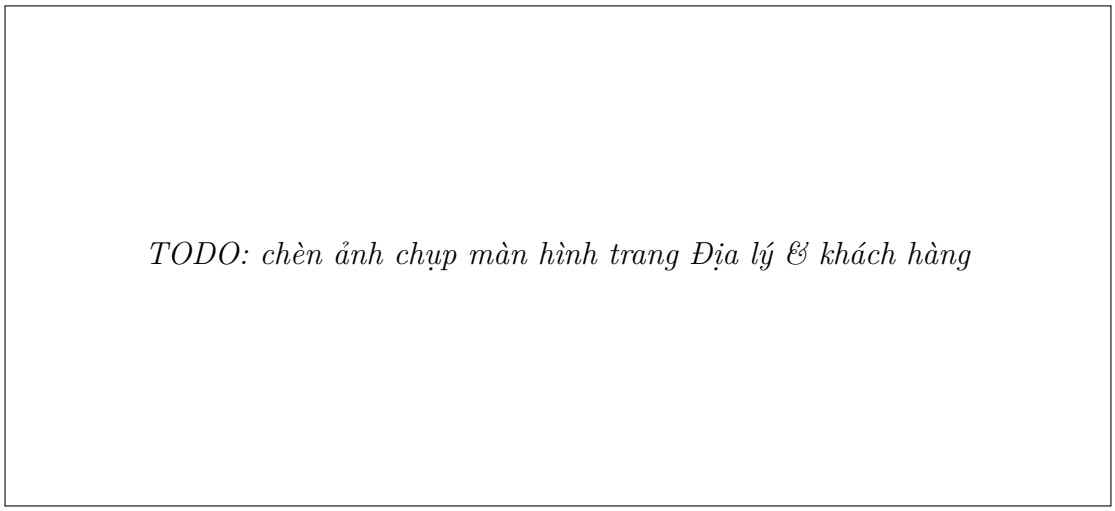
So sánh điểm đánh giá trung bình và số ngày giao trung bình giữa nhóm giao trễ và đúng hạn (`delivery_vs_review()`), rồi tách theo 10 bang và 10 danh mục có số lượng dòng hàng lớn nhất (`delivery_vs_review_by_state()`, `delivery_vs_review_by_category()`).

7.5 Trang 5 – Dự báo & DSS (`page_dss`)

Gồm ba khối tương ứng ba mô hình DSS trình bày ở Mục 8: biểu đồ dự báo doanh thu kèm bảng MAE/MAPE, bảng phân khúc khách hàng RFM + K-Means kèm biểu đồ elbow, và hai khối what-if (giao trễ, khuyến mãi) với thanh trượt tương tác (`st.slider`).



Hình 5: Trang Phân tích đa chiều (OLAP)



Hình 6: Trang Địa lý & khách hàng

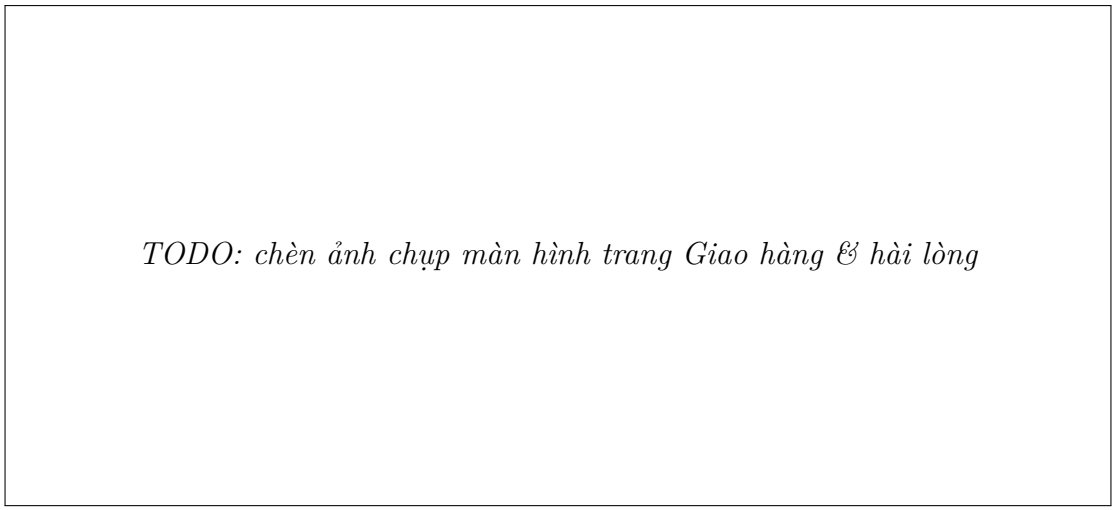
8 Mô hình DSS

Ba mô-đun trong `src/dss/` đều tuân thủ hợp đồng dữ liệu: chỉ nhận dữ liệu đầu vào từ `src/app/queries.py`, không tự mở kết nối CSDL khác. Số liệu dưới đây lấy từ kết quả chạy thực tế (`python src/dss/forecast.py`, `rfm.py`, `whatif.py`) trên kho dữ liệu đã nạp.

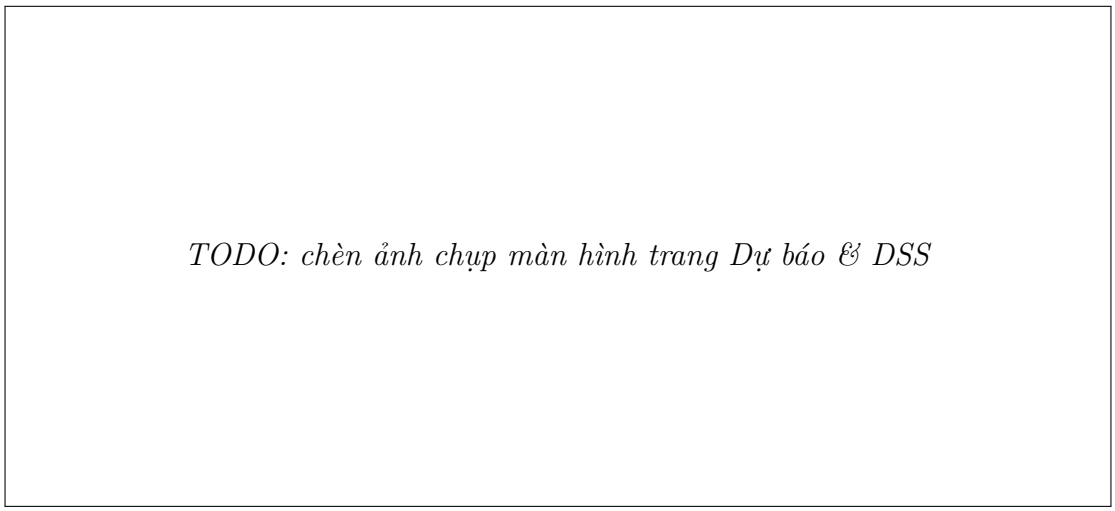
8.1 Dự báo doanh thu (`src/dss/forecast.py`)

Dữ liệu vào. Chuỗi doanh thu theo tháng, 20 điểm từ `2017-01` đến `2018-08` (`monthly_revenue_series_fo`
Khoảng thời gian này được cắt có chủ đích: năm 2016 chỉ có 3 tháng rời rạc và tháng 9/2018 chỉ có 1 đơn, đưa vào sẽ làm nhiễu mô hình.

Phương pháp. Giữ lại 4 tháng cuối (`2018-05..2018-08`) làm tập kiểm tra, 16 tháng đầu làm tập huấn luyện (`TEST_SIZE = 4`). So sánh hai mô hình:



Hình 7: Trang Giao hàng & hài lòng



Hình 8: Trang Dự báo & DSS

- **Baseline (trung bình trượt):** dự báo phẳng, bằng trung bình 3 tháng cuối của tập huấn luyện, lặp lại cho toàn bộ chân trời dự báo (`_naive_moving_average_forecast`, `window=3`).
- **Holt (xu hướng tuyến tính):** `statsmodels.tsa.holtwinters.ExponentialSmoothing` với `trend="add"`, `seasonal=None` – *không* có thành phần mùa vụ vì chuỗi quá ngắn để ước lượng đáng tin cậy. Mô hình được huấn luyện lại trên toàn bộ 20 tháng để cho ra dự báo 1 bước kế tiếp, kèm khoảng tin cậy 95% tính từ độ lệch chuẩn phần dư (`resid_std`).

Kết quả thực tế. (Bảng 11)

Dự báo tháng kế tiếp sau `2018-08` (mô hình Holt, huấn luyện lại trên toàn bộ chuỗi): **854.929,55**, khoảng tin cậy 95%: **643.623,52 .. 1.066.235,57**.

Bảng 11: Sai số dự báo trên tập kiểm tra (4 tháng 2018-05..2018-08)

Mô hình	MAE	MAPE (%)
Baseline (trung bình trượt)	69.432,04	7,85
Holt (xu hướng tuyến tính)	281.179,04	32,24

Vì sao Holt kém baseline. Doanh thu tăng gần như liên tục đến đỉnh khoảng 1,0 triệu ở tháng 11/2017, rồi đi ngang và giảm nhẹ. Holt ước lượng xu hướng tăng tuyến tính từ 16 tháng huấn luyện (đến `2018-04`), nên dự báo cao hơn doanh thu thực của 4 tháng kiểm tra. Baseline là một đường phẳng và bám sát mức doanh thu tương đối ổn định của giai đoạn này hơn. Đây không phải lỗi cài đặt: chuỗi chỉ có 20 tháng, chưa đủ hai chu kỳ mùa vụ để kiểm chứng một mô hình có xu hướng.

8.2 Phân khúc khách hàng RFM + K-Means (`src/dss/rfm.py`)

Cái bẫy F (Frequency) và cách xử lý. Trong 94.983 khách hàng (theo `customer_key` đã gộp theo người thật), chỉ 2.887 người (khoảng 3%) có từ 2 đơn trở lên. Vì vậy Frequency tính theo cách kinh điển gần như luôn bằng 1 và không thể chia phân vị (`qcut`) một cách có ý nghĩa. Mô-đun thay F bằng hai đặc trưng: **`repeat_flag`** (cờ nhị phân: 1 nếu khách có ≥ 2 đơn, ngược lại 0) và **`avg_review`** (điểm đánh giá trung bình của khách), vì điểm đánh giá cho biết thêm về hành vi của khách, còn cột tần suất gần như không đổi thì không.

Dữ liệu vào và đặc trưng. Từ `customer_order_history()` (1 dòng / đơn hàng), gộp theo `customer_key` thành 4 đặc trưng: `recency_days` (số ngày từ lần mua gần nhất đến ngày tham chiếu **2018-09-03**, một tháng sau đơn cuối trong cửa sổ phân tích), `monetary` (tổng chi tiêu), `repeat_flag`, `avg_review` (NULL được điền bằng trung vị của khách khác). Dữ liệu được chuẩn hóa bằng `StandardScaler` trước khi phân cụm.

Chọn K. Chạy K-Means với $K \in [2, 6]$, 10 lần khởi tạo mỗi K (`n_init=10`). Vì `silhouette_score` có độ phức tạp $O(n^2)$, tính trên mẫu con 5.000 khách hàng. Kết quả (Bảng 12): K=2 có silhouette cao nhất (0,681) nhưng mô-đun giới hạn lựa chọn trong khoảng 3–4 theo yêu cầu đề bài (`chosen_k = max(3, min(4, chosen_k))`) để có đủ số phân khúc cho hành động nghiệp vụ; trong khoảng đó K=3 có silhouette tốt nhất.

K đã chọn: 3, silhouette = 0,411.

Hồ sơ phân khúc. (Bảng 13) Việc đặt tên phân khúc theo thứ tự ưu tiên trong `_name_segments`: cụm có tỷ lệ mua lại cao nhất (và chi tiêu cao nhất) được gọi là *Khách giá trị cao*; trong các cụm còn lại (chủ yếu khách mua 1 lần, nơi recency/monetary gần như không khác biệt – chính `avg_review` là yếu tố phân tách), cụm có điểm đánh giá cao

Bảng 12: Inertia và silhouette theo K

K	Inertia	Silhouette
2	283.974,6	0,681
3	208.709,2	0,411
4	153.541,4	0,399
5	108.683,3	0,422
6	95.277,0	0,430

nhất là *Khách mới* (hài lòng ở đơn đầu, đáng để chăm sóc cho đơn thứ hai), cụm có điểm đánh giá thấp nhất là *Khách ngủ đông*.

Bảng 13: Hồ sơ từng phân khúc khách hàng

Phân khúc	Recency (ngày)	Monetary	Repeat flag	Review TB	Số khách	%
Khách ngủ đông	248,5	149,5	0,000	1,89	20.300	21,4
Khách mới	242,5	134,8	0,000	4,75	71.792	75,6
Khách giá trị cao	226,6	271,1	0,999	4,17	2.891	3,0

Nhóm *Khách giá trị cao* (3,0% khách hàng) gần như trùng khít với nhóm khách mua lại (`repeat_flag` trung bình 0,999) và có chi tiêu cao nhất. Hai nhóm còn lại đều là khách mua 1 lần (repeat_flag = 0) nhưng tách biệt rõ theo mức độ hài lòng: *Khách mới* hài lòng (4,75/5, chiếm 75,6% khách hàng) trong khi *Khách ngủ đông* không hài lòng (1,89/5, 21,4%).

Hành động đề xuất. Khách giá trị cao: chăm sóc VIP, ưu đãi độc quyền, giao hàng ưu tiên. Khách mới: gửi voucher cho đơn thứ 2, gợi ý sản phẩm liên quan để biến thành khách mua lại. Khách ngủ đông: khảo sát lý do không hài lòng, chiến dịch win-back/giảm giá để tránh mất khách vĩnh viễn.

8.3 Mô hình what-if (`src/dss/whatif.py`)

Mô-đun có hai mô hình với **mức căn cứ khác nhau**: một mô hình dựa trên số đo trong DW, một mô hình dựa trên giả định của người dùng. Giao diện và báo cáo đều tách bạch hai loại này.

What-if 1: Giảm giao trễ → điểm hài lòng – dựa trên số đo thực tế. Dựa trên quan hệ *đã đo được* trong DW (phần A, Bảng 9): đơn giao trễ có điểm đánh giá trung bình **2,55**, đơn đúng hạn/sớm **4,21**. Mô hình giả định hai điểm trung bình này không đổi, chỉ tỷ trọng hai nhóm thay đổi, rồi tính trung bình có trọng số (`weighted_avg = p*2.55 + (1-p)*4.21`). Đây là phép nội suy tuyến tính đơn giản, *không phải* mô hình nhân quả đầy đủ. Tỷ lệ giao trễ hiện tại trên dữ liệu: **7,91%**. Ví dụ kết quả (Bảng 14).

Bảng 14: What-if giảm tỷ lệ giao trễ (hiện tại: 7,91%)

Tỷ lệ trễ mục tiêu (%)	Điểm TB dự kiến	Δ so với hiện tại
7,91 (hiện tại)	4,079	+0,000
4,91	4,128	+0,050
1,91	4,178	+0,100
0,00	4,210	+0,131

What-if 2: Khuyến mãi theo danh mục → doanh thu – dựa trên giả định người dùng. Người dùng nhập mức giảm giá (`discount_pct`) và **độ co giãn cầu theo giá** (`elasticity`, quy ước dương = cầu tăng khi giá giảm). Công thức: $\%\Delta\text{quantity} = \text{elasticity} \times \%\Delta(-\text{price})$, từ đó $\text{Revenue}_{new} = \text{Revenue}_{base} \times (1-d) \times (1 + \text{elasticity} \times d)$ với d là mức giảm giá. **Độ co giãn là giả định do người dùng tự đặt, không phải số đo thực tế hay dự báo chắc chắn**; giao diện luôn hiển thị cảnh báo này. Ví dụ với danh mục `health_beauty` (doanh thu nền: 1.255.695,00, Bảng 15):

Bảng 15: What-if khuyến mãi – danh mục health_beauty

Giảm giá (%)	Co giãn	Doanh thu dự kiến	Δ (%)
10	1,0	1.243.138	$-1,00$
10	2,0	1.356.151	$+8,00$
20	1,5	1.305.923	$+4,00$

Với co giãn = 1,0 (cầu tăng đúng bằng % giảm giá), doanh thu vẫn giảm nhẹ vì phần tăng số lượng không bù đủ phần giảm giá trên từng đơn vị; cần co giãn > 1 (cầu nhạy hơn giá) thì khuyến mãi mới làm tăng doanh thu trong mô hình này.

9 Đánh giá

Bảng 16: Tổng hợp chỉ số đánh giá các mô hình DSS

Mô hình	Chỉ số	Giá trị
Dự báo – Baseline	MAE / MAPE	69.432,04 / 7,85%
Dự báo – Holt	MAE / MAPE	281.179,04 / 32,24% (kém hơn baseline)
RFM – K-Means	K đã chọn / Silhouette	3 / 0,411
What-if giao trễ	Căn cứ	Số đo thực tế (2,55 vs 4,21)
What-if khuyến mãi	Căn cứ	Giả định người dùng (độ co giãn)

Hạn chế của từng mô hình.

- **Dự báo doanh thu.** Chuỗi chỉ có 20 tháng, chưa đủ 2 chu kỳ mùa vụ (24 tháng trở lên) nên không thể ước lượng và kiểm chứng một mô hình mùa vụ đáng tin cậy;

vì vậy nhóm không dùng Holt-Winters đầy đủ mà chỉ dùng Holt không mùa vụ. Trên dữ liệu hiện tại, Holt có sai số *cao hơn* baseline vì xu hướng tăng ước lượng từ giai đoạn huấn luyện không còn đúng ở giai đoạn kiểm tra (doanh thu đi ngang sau đỉnh tháng 11/2017). Khoảng tin cậy 95% của dự báo tháng kế tiếp khá rộng (643.623,52 – 1.066.235,57), phản ánh độ bất định lớn của chuỗi ngắn.

- **RFM + K-Means.** Silhouette 0,411 ở K=3 là mức *trung bình*, không phải phân cụm tách biệt rõ ràng; K=2 có silhouette cao hơn (0,681) nhưng bị giới hạn lại trong khoảng 3–4 theo yêu cầu đề bài để có đủ phân khúc hành động. F (Frequency) đã được thay bằng cờ nhị phân mua lại + điểm đánh giá trung bình vì ~97% khách hàng chỉ có 1 đơn, nên đây không phải RFM kinh điển mà là một biến thể phù hợp với đặc điểm dữ liệu.
- **What-if giao trễ.** Giả định điểm trung bình của mỗi nhóm (trễ/đúng hạn) không đổi khi tỷ trọng thay đổi – là một phép nội suy, không phải mô hình nhân quả (không loại trừ các yếu tố gây nhiễu khác ảnh hưởng đến điểm đánh giá).
- **What-if khuyến mãi.** Độ co giãn cầu theo giá là tham số *người dùng tự nhập*, chưa được ước lượng từ dữ liệu lịch sử (DW không có đủ các đợt khuyến mãi có ghi nhận giá gốc/giá giảm để ước lượng co giãn thực tế). Kết quả chỉ mang tính minh họa kịch bản, không phải dự báo.

10 Hạn chế và hướng phát triển

10.1 Hạn chế hiện tại

- **Chưa có ảnh chụp màn hình dashboard.** Báo cáo này dùng khung `\fbox` làm chỗ trống (TODO) cho 5 trang dashboard; cần chụp và chèn ảnh thật trước khi nộp/thuyết trình.
- **Chuỗi thời gian ngắn.** 20 tháng dữ liệu không đủ để kiểm định mô hình mùa vụ hoặc các mô hình dự báo phức tạp hơn (ARIMA mùa vụ, Prophet…).
- **Mô hình Holt hiện đang kém hơn baseline** trên tập kiểm tra 4 tháng cuối – là một kết quả thật, không phải lỗi cài đặt, nhưng cho thấy cần thận trọng khi dùng Holt để ra quyết định thực tế ở giai đoạn dữ liệu hiện tại.
- **F (Frequency) trong RFM bị thay thế** bằng cờ nhị phân mua lại vì đặc thù dữ liệu (hầu hết khách chỉ mua 1 lần trong giai đoạn quan sát), nên các phân khúc không hoàn toàn tương đương RFM kinh điển.
- **Độ co giãn cầu trong what-if khuyến mãi** là tham số giả định, chưa được kiểm chứng bằng dữ liệu thực nghiệm (A/B test hay lịch sử khuyến mãi).

10.2 Hướng phát triển

1. Thu thập/tích lũy thêm dữ liệu theo thời gian để chuỗi doanh thu đạt tối thiểu 24 tháng, cho phép dùng Holt-Winters có thành phần mùa vụ và so sánh với các mô hình như SARIMA hoặc Prophet.
2. Ghi nhận các đợt khuyến mãi thực tế (giá gốc, giá giảm, doanh số trước/sau) để ước lượng độ co giãn cầu theo giá từ dữ liệu thay vì để người dùng tự giả định.
3. Bổ sung ảnh chụp màn hình và video demo thực tế cho từng trang dashboard; cân nhắc thêm bản đồ theo mã bưu chính nếu phần A mở rộng dùng dữ liệu địa lý chi tiết.

Tài liệu tham khảo

[1] W. H. Inmon, *Building the Data Warehouse*, 4th ed., Wiley, 2005.

[2] R. Kimball, M. Ross, *The Data Warehouse Toolkit*, 3rd ed., Wiley, 2013.

[3] Olist, *Brazilian E-Commerce Public Dataset by Olist*, Kaggle (nguồn dữ liệu).